Universidad Europea



Ecosistema Big Data

Cadena de valor del dato

Fundamentos de Big Data

Grado en Física

- *Google Maps elige la ruta por la que vamos a la playa en coche.*
- *Tesla conduce el coche por nosotros.*
- *Netflix recomienda la pelicula o serie que vamos a ver por la noche con nuestra pareja.*
- *TikTok nos muestra videos que luego compartiremos con nuestros amigos.*
- *Amazon nos sugiere productos para comprar en Navidad, San Valentín o Black Friday.*
- *Spotify escoge los cantantes que debemos oír en nuestro día a día.*
- ....

Universidad Europea

“Si dejamos que la Inteligencia Artificial tome decisiones por nosotros… ¿seguimos siendo libres?”

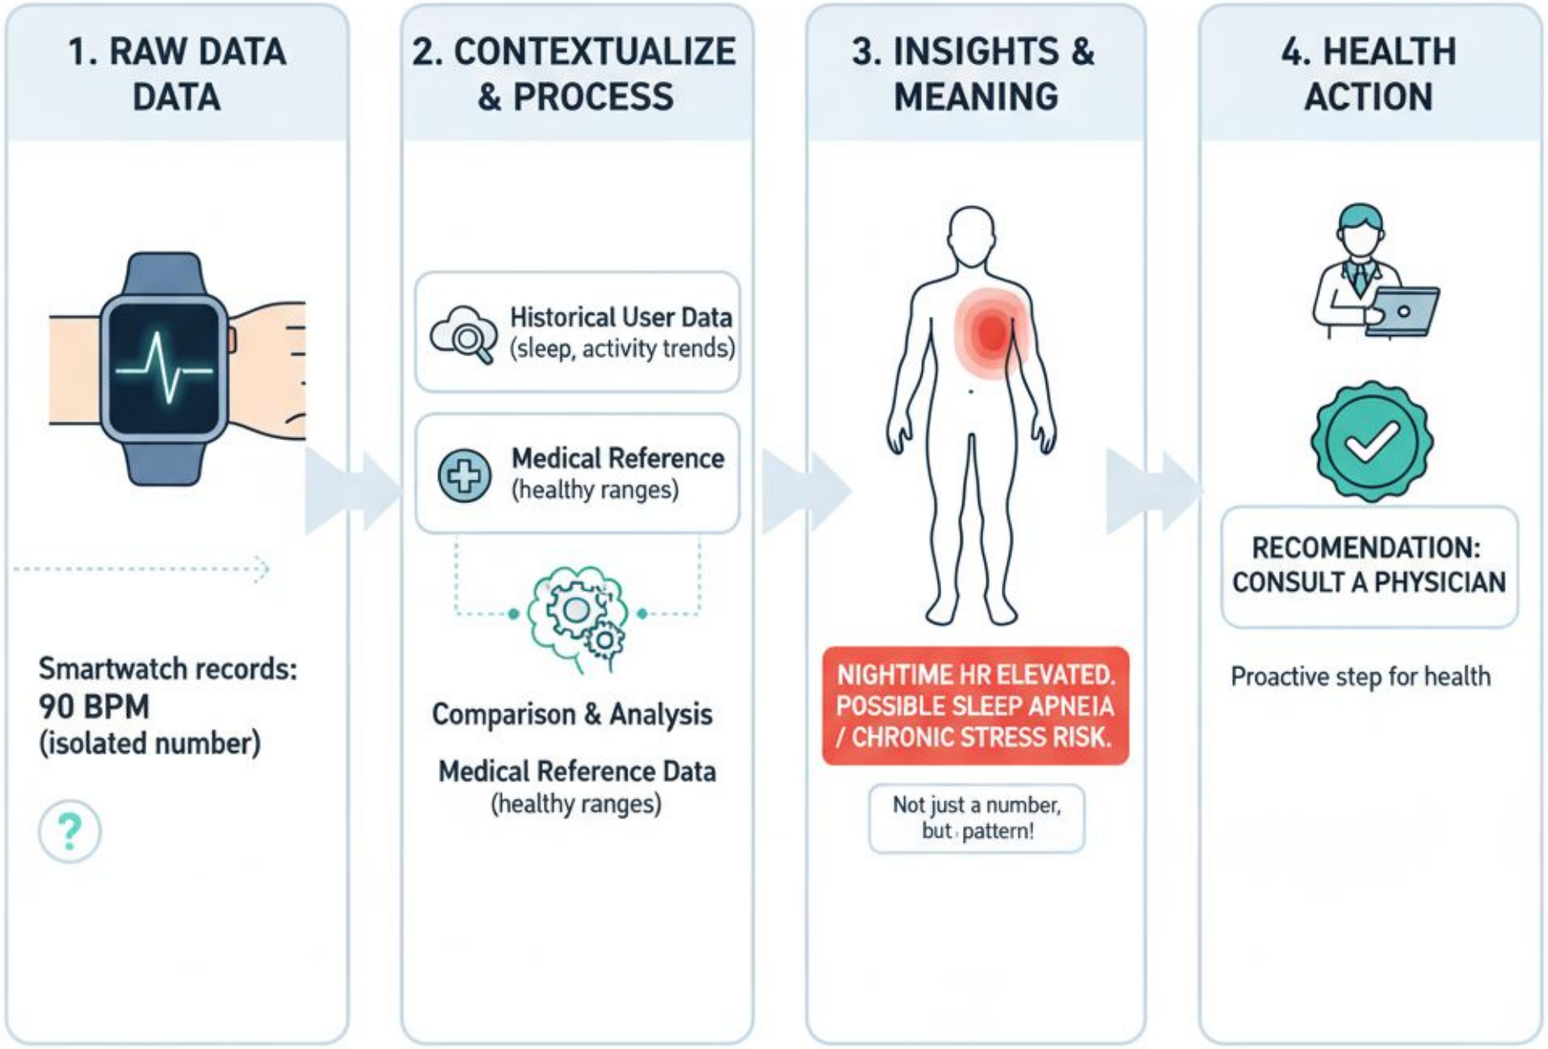
1. ¿Hasta qué punto esas decisiones son realmente “tuyas”?
2. ¿Te hacen la vida más fácil o te quitan libertad?
3. ¿Confías más en tu intuición o en los datos que maneja el algoritmo?

CONTENIDOS

1. **Del dato en crudo a la decisión.**
2. Ecosistema Big Data y Cadena de valor del dato.
3. Retos y Consideraciones.

1. Del dato en crudo a la decisión

No es el dato puntual lo que aporta valor, sino cómo se **integra** con contexto, se **procesa** y se convierte en una **decisión**.



CONTENIDOS

1. Del dato en crudo a la decisión.
2. **Ecosistema Big Data y Cadena de valor del dato.**
3. Retos y Consideraciones.

2. Ecosistema Big Data y Cadena de Valor del Dato



Universidad Europea

2. Cadena de Valor del Dato

1. *Captura / Generación*: fase en la que los datos se originan. Pueden provenir de cualquier sistema que produzca información.
2. *Ingesta*: proceso mediante el cual los datos, una vez generados, son trasladados hacia las plataformas donde serán gestionados, Puede hacerse en tiempo real (streaming) o en diferido (batch).
3. *Procesamiento*: preparar los datos para su uso: limpiarlos, transformarlos, combinarlos con otras fuentes y organizarlos.



Universidad Europea

2. Cadena de Valor del Dato

4. *Almacenamiento:* los datos se guardan en repositorios adecuados a su naturaleza y volumen.
5. **Analítica / Machine Learning**: fase en la que se aplican métodos analíticos para descubrir patrones, generar predicciones o recomendaciones, y obtener conocimiento a partir de los datos almacenados.
6. **Visualización / Decisión**: los resultados se presentan de forma clara mediante gráficos, dashboards o informes, para ayudar a tomar decisiones fundamentadas.

2.1. Captura / Generación

Fuentes de Datos

- **IoT y sensores** (temperatura, coches conectados, wearables).
- **Transacciones** (bancos, e-commerce).
- **Logs** (sistemas TI, servidores web).
- **Redes sociales** (texto, imágenes, vídeos).

Ejemplo: En Amazon, cada clic en la web genera un dato que se guarda en logs. Aislado no vale mucho, pero sumado a millones permite entender patrones de compra.

2.1. Captura / Generación

Según el ORIGEN del dato

1. *Datos humanos*: creados directamente por personas en su interacción con sistemas.

   Ej.: formularios web, redes sociales, correos electrónicos.

2. *Datos de máquina*: generados automáticamente por dispositivos o sistemas sin intervención humana directa.

   Ej.: logs de servidores, sensores IoT, registros de producción industrial.

2.1. Captura / Generación

Según el NATURALEZA del dato

1. **Estructurados**: *organizados en tablas y campos definidos.*

   Ej.: bases de datos relacionales, registros de transacciones.

2. **Semiestructurados**: *contienen etiquetas o jerarquías pero no siguen un modelo rígido.*

   Ej.: JSON, XML, logs de aplicaciones..

3. **No estructurados**: *no tienen un formato predefinido ni uniforme.*

   Ej.: imágenes, vídeos, audio, texto libre.

2.1. Captura / Generación

Según el PROCEDENCIA del dato

1. *Fuentes internas: provienen de procesos, sistemas o interacciones propias de la organización.*

   Ej.: ERP, CRM, registros de ventas, atención al cliente.

2. *Fuentes externas: generados fuera de la organización y adquiridos o consumidos como insumo.*

   Ej.: open data gubernamental, redes sociales, proveedores de datos de mercado.

2.1. Captura / Generación

Según el DINÁMICA DE GENERACIÓN del dato

1. *Datos estáticos: cambian poco o nada a lo largo del tiempo.*

   Ej.: censos, catálogos de productos..

2. *Datos dinámicos: se generan y actualizan continuamente.*

   Ej.: tráfico web en tiempo real, lecturas de sensores, cotización bursátil.

2.2. Ingesta

Batch (por lotes)

Los datos se acumulan durante un periodo y se transfieren en bloques de información.

Adecuado cuando:

- No es necesario tiempo real.
- El volumen de datos es muy grande.

Ejemplo: generar informes mensuales de facturación.

2.2. Ingesta

Batch (por lotes)

Ventajas

- Sencillo de implementar.
- Eficiente para cargas masivas.

Limitaciones:

- No sirve para escenarios donde la inmediatez es crítica.

2.2. Ingesta

Streaming (Tiempo Real)

Los datos fluyen continuamente y se procesan al instante de ser generados.

Adecuado cuando:

- Se necesitan respuestas inmediatas.
- La información pierde valor si se retrasa.

Ejemplo: recomendaciones instantáneas en Netflix o TikTok..

2.2. Ingesta

Streaming (Tiempo Real)

Ventajas

- Decisiones inmediatas.
- Alta competitividad en entornos dinámicos.

Limitaciones:

- Complejidad técnica.
- Mayor coste de infraestructura.

2.2. Ingesta

	ETL	ELT
Definición	Los datos se extraen, se transforman en un servidor intermedio y luego se cargan en el sistema destino.	Los datos se extraen y se cargan tal cual en bruto al destino; la transformación ocurre allí mismo.
Arquitectura	Propio de entornos tradicionales Data Warehouses	Propio de entornos Big Data Data Lakes o Nube
Flexibilidad	Limitada: los datos deben estar bien definidos antes de la carga.	Alta: permite almacenar datos en bruto y decidir después cómo transformarlos.
Velocidad	Más lento en cargas masivas, ya que la transformación es previa.	Más rápido para ingesta inicial, la transformación se distribuye.
Coste	Costoso en ETL servers.	Optimiza costes al aprovechar el poder de cómputo del sistema de almacenamiento.
Ejemplo típico	Cargar datos limpios a un Data Warehouse de Oracle.	Cargar logs en bruto a un Data Lake (S3, HDFS) y transformarlos con Spark.

2.2. Ingesta

Tipo	Herramientas	Características principales
Batch	Apache Sqoop, Talend, Pentaho	Migración masiva entre bases de datos y data warehouses; adecuado para cargas periódicas.
Streaming	Apache Kafka, Apache Flume, AWS Kinesis, Azure Event Hubs	Procesamiento en tiempo real de flujos de eventos, altamente escalables y distribuidos.
Híbridas	Apache NiFi, Airbyte, Fivetran	Permiten tanto cargas batch como streaming, fáciles de integrar con múltiples orígenes.

2.3. Procesamiento

Limpieza de datos (Data Cleaning)

- Eliminación de errores, inconsistencias o duplicados.
- Corrección de valores imposibles o atípicos.
- Normalización de formatos.

Ejemplo error: edad = 500 años.
Ejemplo normalizar: fecha como YYYY-MM-DD

2.3. Procesamiento

Validación de datos

- Comprobación de que los datos cumplen reglas y restricciones.
- Garantiza que los datos sean utilizables para análisis posterior.

Ejemplo: un campo “correo electrónico” debe tener el patrón @.

2.3. Procesamiento

Transformación de datos (Data Transformation)

- Conversión de datos de un formato a otro.
    a. Escalar valores (a).
    b. Codificación de categorías.
    c. Unificación de sistemas de medida.

Ejemplo a: normalización de variables en ML).

Ejemplo b: convertir “rojo, azul, verde” en numérico.

Ejemplo c: “millas” → “km”.

2.3. Procesamiento

Integración de Datos (Data Integration)

- Combinar información procedente de diferentes fuentes.
- Aquí suelen aparecer problemas de duplicidad de registros o falta de claves comunes.

Ejemplo: unir datos de ventas (ERP) con comportamiento web (clickstream).

2.3. Procesamiento

Enriquecimiento de datos (Data Enrichment)

- Añadir información externa para aumentar el valor del dato.

Ejemplo: a direcciones postales se les añade coordenadas GPS o datos socioeconómicos de la zona.

2.3. Procesamiento

Agregación y resumen (Data Aggregation / Summarization)

- Reducción de datos a métricas clave (KPIs) mediante agregación o resumen.

Ejemplo: en vez de millones de transacciones, mostrar total de ventas por día o región.

2.3. Procesamiento

Anonimización y enmascaramiento

- Proceso clave por motivos de privacidad y cumplimiento normativo (GDPR, LOPDGDD).
- Consiste en eliminar o transformar identificadores sensibles para preservar la confidencialidad.

Ejemplo: convertir un número de DNI en una clave tokenizada: XXXX333XXXX0001XXXA

2.3. Procesamiento

Catalogación y metadatos (Data Cataloging)

- Organización de los datos para que sean localizables y comprensibles.
- Creación de metadatos: quién generó el dato, cuándo, con qué formato, qué significa.
- Es la base del gobierno del dato.

Ejemplo: 2025-01-01; <admin>; data_user: True.

2.3. Procesamiento

Normalización y estandarización

- Homogeneizar datos que vienen en distintos formatos o estructuras.

Ejemplo: nombres escritos en mayúsculas o minúsculas, direcciones con abreviaturas diferentes.

2.3. Procesamiento

Calidad del dato (Data Quality Management)

- Proceso transversal a todos los anteriores.
- Incluye métricas de completitud, consistencia, unicidad, validez y precisión.
- Sin calidad, no hay confianza en las decisiones basadas en datos.

2.4. Almacenamiento

- La elección del **sistema de almacenamiento no es única** ni **excluyente**.
- En un ecosistema Big Data real conviven múltiples opciones:
  - Datos en bruto en un Data Lake.
  - Datos limpios en un DWH.
  - Consultas rápidas en NoSQL.
  - ...

2.4. Almacenamiento

Bases de Datos Relacionales (SQL)

Sistemas estructurados en tablas con filas y columnas.

- Modelo rígido, esquema definido.
- Fáciles de consultar con SQL.
- Buena integridad y consistencia.

Ejemplo: MySQL, PostgreSQL, Oracle Database, Microsoft SQL Server.

2.4. Almacenamiento

Bases de Datos Relacionales (SQL)

Ventajas

- Idóneas para transacciones y datos estructurados.

Limitaciones:

- Escalan mal con datos no estructurados o en grandes volúmenes y en entornos distribuidos.

2.4. Almacenamiento

Bases de Datos No Relacionales (NoSQL)

Sistemas no relacionales, diseñados para datos masivos, flexibles y distribuidos.

Tipos principales:

a) *Clave-valor*: simples y rápidas
b) *Columnar*: optimizadas para grandes volúmenes analíticos.
c) *Documentales*: almacenan documentos semiestructurados.
d) *Grafos*: para modelar relaciones complejas.

Ejemplo a: Redis, DynamoDB. *Ejemplo b: Cassandra, HBase.*
Ejemplo c: MongoDB, CouchDB *Ejemplo d: Neo4j*

2.4. Almacenamiento

Bases de Datos Relacionales (SQL)

Ventajas

- Flexibles, escalables y soportan variedad de datos.

Limitaciones:

- Sacrifican la consistencia estricta por la disponibilidad y la escalabilidad (modelo BASE vs. ACID).

2.4. Almacenamiento

Data Warehouse (DWH)

Repositorio centralizado orientado a análisis histórico de datos estructurados.

- Modelo en estrella o copo de nieve.
- Optimizado para consultas analíticas (OLAP).
- Integra datos de múltiples fuentes (tras ETL).

Ejemplo: Teradata, Snowflake, Google BigQuery, Amazon Redshift.

2.4. Almacenamiento

Data Warehouse (DWH)

Ventajas

- Ideal para Reporting, Business Intelligence, KPIs, OKRs, etc.

Limitaciones:

- Poco flexible con datos no estructurados; costes altos.

2.4. Almacenamiento

Data Lake

Repositorio masivo donde se almacenan datos en bruto, de cualquier tipo y en cualquier formato.

- Guarda datos estructurados, semiestructurados y no estructurados.
- Escalable y barato (especialmente en la nube).
- Flexible: “schema-on-read”.

Ejemplo: Hadoop HDFS, Amazon S3, Azure Data Lake, Google Cloud Storage.

2.4. Almacenamiento

Data Lake

Ventajas

- Versátil: almacena TODO sin necesidad de decidir previamente cómo usarlo.

Limitaciones:

- Si no se gestiona bien, puede convertirse en un Data Swamp (pantano de datos).

2.4. Almacenamiento

Data Lakehouse

Arquitectura híbrida que combina lo mejor del Data Warehouse y del Data Lake.

- Almacenar datos en bruto como un Data Lake.
- Añade transaccionalidad y gestión de metadatos como en un DWH.
- Optimizado tanto para BI como para ML.

Ejemplo: Databricks Delta Lake, Apache Iceberg, Apache Hudi.

2.4. Almacenamiento

Sistemas en la Nube (Cloud Storage)

Servicios gestionados por proveedores cloud.

- Escalabilidad prácticamente infinita.
- Pago por uso.
- Integración con ecosistemas de analítica y ML en la nube.

Ejemplo: Amazon S3, Google Cloud Storage, Azure Blob Storage.

2.5. Analítica / Machine Learning

Análisis Descriptivo
¿Qué ha pasado?

Análisis Diagnóstico
¿Por qué ha pasado?

Análisis Predictivo
¿Qué pasará?

Análisis Prescriptivo
¿Qué debería hacer?

2.5. Analítica / Machine Learning

Análisis Descriptivo - ¿Qué ha pasado?

Resumir e interpretar datos históricos para entender el presente y el pasado mediante el uso de métricas, informes y dashboards.

- Herramientas comunes: Excel, Power BI, Google Data Studio, HRMS básicos.

Ejemplo: un operador de telecomunicaciones analizando el consumo de datos móviles por hora y ciudad.

2.5. Analítica / Machine Learning

Análisis Diagnóstico - ¿Por qué ha pasado?

Identificar las causas o factores que explican los fenómenos detectados para encontrar patrones de causalidad.

- Técnicas comunes: Análisis de correlaciones, regresiones simples, segmentaciones..

Ejemplo: un servicio de streaming analiza por qué un vídeo pierde audiencia: detecta que ocurre tras un anuncio demasiado largo.

2.5. Analítica / Machine Learning

Análisis Predictivo - ¿Qué pasará?

Anticiparse a eventos futuros mediante modelos estadísticos o de machine learning.

- Técnicas: Modelos de regresión, clasificación, árboles de decisión, clustering, etc.

Ejemplo: Amazon Forecast anticipa la demanda de un producto para planificar inventario y logística.

2.5. Analítica / Machine Learning

Análisis Prescriptivo - ¿Qué debería hacer?

Sugerir acciones concretas para alcanzar objetivos o resolver problemas basados en predicciones.

- Técnicas: Simulaciones, modelos de optimización, algoritmos de decisión.

Ejemplo: Plataformas de delivery (Uber Eats, Glovo) optimizando rutas en tiempo real para reducir tiempos de entrega.

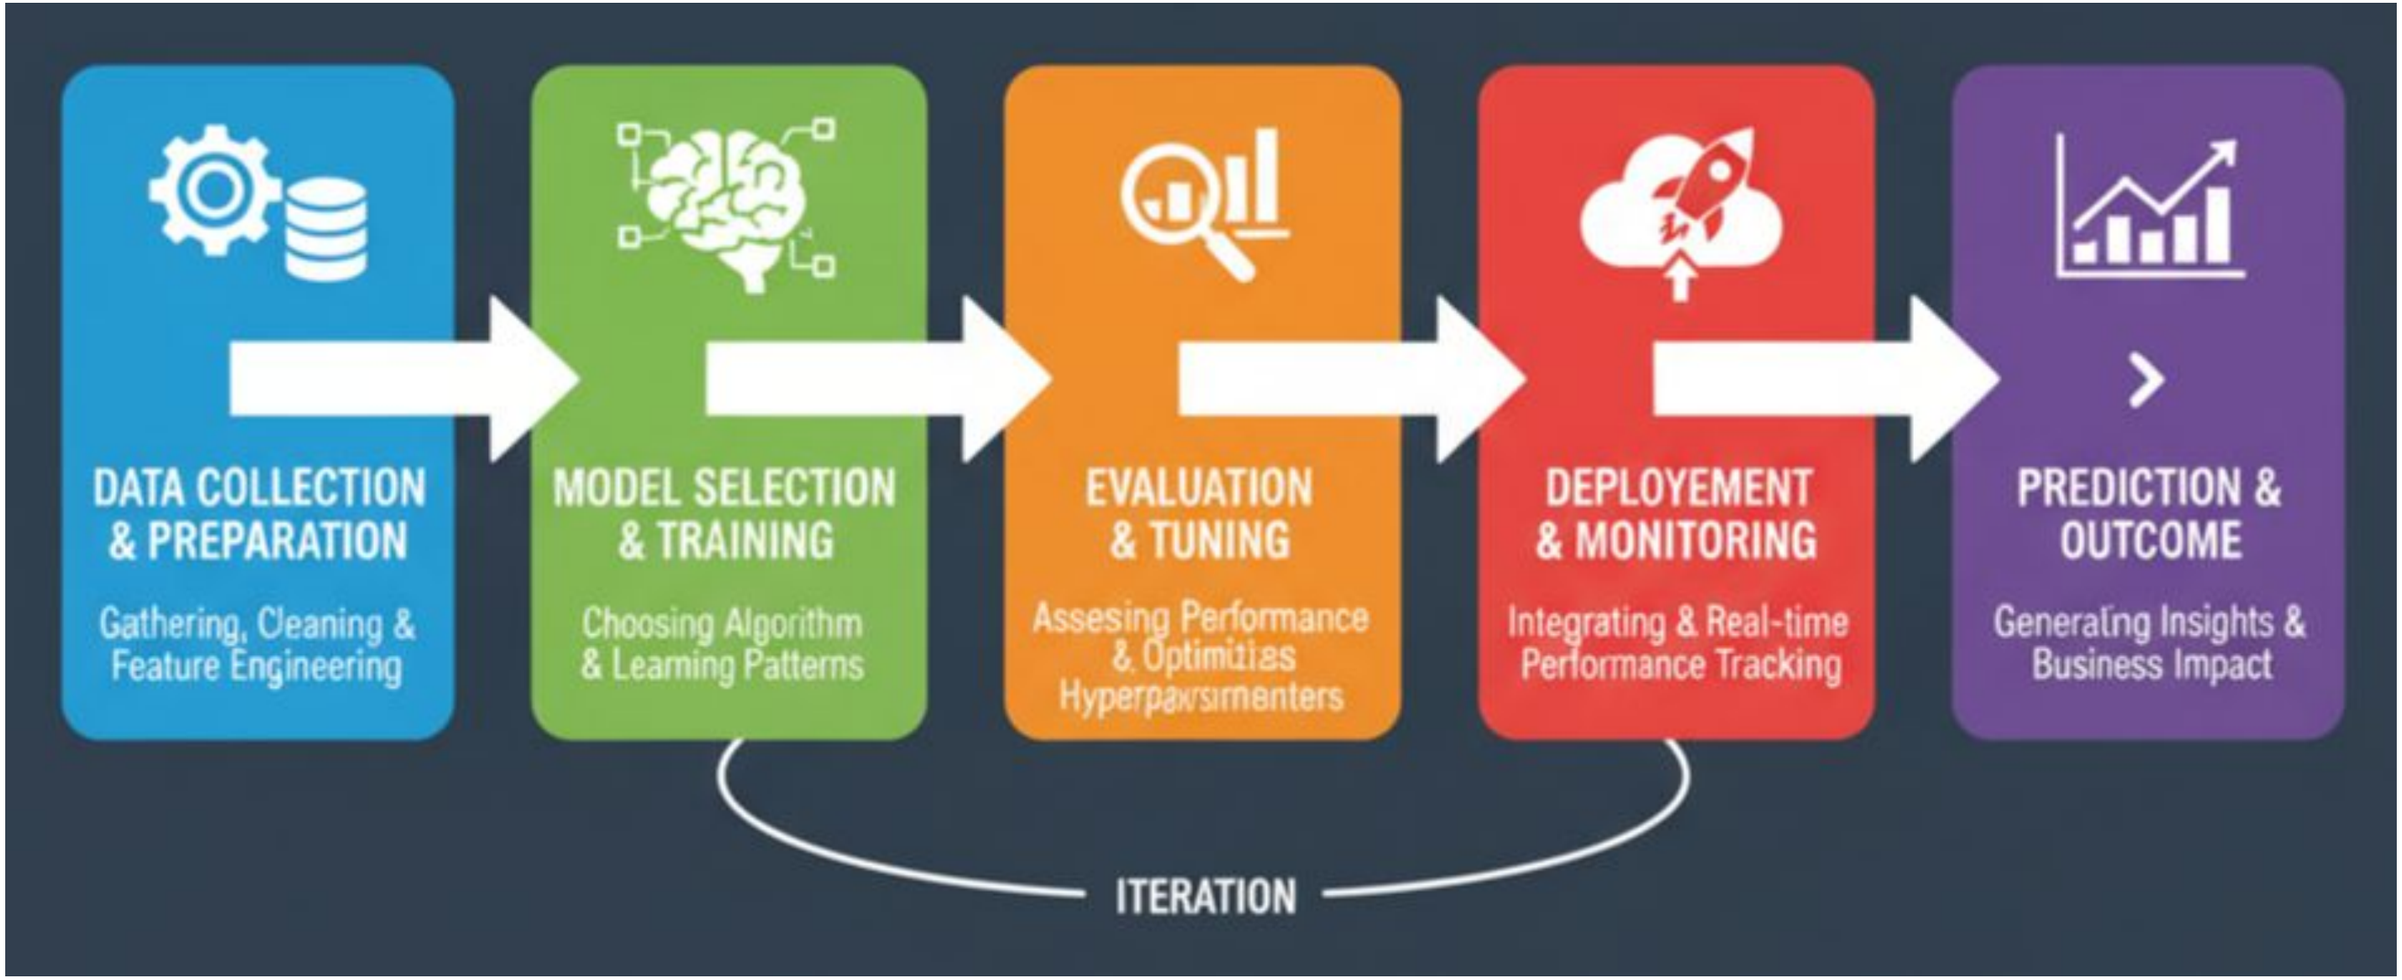
2.5. Analítica / Machine Learning

Machine Learning

Conjunto de técnicas que permiten ***entrenar modelos con grandes volúmenes de datos*** para que aprendan **patrones y realicen predicciones** o recomendaciones de manera automática.

- Netflix: modelos de recomendación.
- Amazon: logística anticipada.
- Spotify: listas personalizadas.
- Google Photos: clasificación de imágenes.

2.5. Analítica / Machine Learning



2.6. Visualización / Decisión

Proceso de presentar los resultados del análisis de forma ***clara, comprensible y útil*** para la toma de decisiones.

En Big Data no basta con tener modelos complejos. Si los resultados no se comunican bien, pierden impacto y valor.

■ INFORMACIÓN CORONAVIRUS S; ES LA SEGUNDA CIFRA MÁS ALTA DE TODA LA



■ DIRECTO

■ Redacción 'laSexta Noticias'

MUERTES NOTIFICADAS



Fuente: Ministerio de Sanidad

■ EVOLUCIÓN DEL CORONAVIRUS EN ESPAÑA

SANIDAD NOTIFICA 42.885 CASOS EN 24 HORAS, LA SEGUNDA CIFRA MÁS ALTA DE LA PANDEMIA

ALTERNATIVAS PLEBISCITO DE SALIDA

AGOSTO



FUENTE: C



EVOLUCIÓN IPC



CONEXIÓN REDACCIÓN

LA INFLACIÓN SE DESACELERA EN OCTUBRE

ÚLTIMA HORA

2.6. Visualización / Decisión

Funciones Principales

- ***Explorar***: el analista navega en los datos para descubrir patrones y anomalías.

  Ej.: filtrar transacciones sospechosas en tiempo real.

- ***Explicar***: comunica hallazgos clave a perfiles no técnicos.

  Ej.: un dashboard que muestra los 3 KPIs más críticos en ventas.

- ***Convencer***: busca influir en decisiones.

  Ej.: la baja satisfacción del cliente impacta en la caída de ingresos.

2.6. Visualización / Decisión

Herramientas Fundamentales

- ***Dashboards interactivos***: Tableau, Power BI, Qlik o Looker. Permiten KPIs en tiempo real, filtros y segmentaciones…
- ***Librerías de visualización***: Python: Matplotlib, Plotly o Seaborn.
- ***Visualización en la Nube***: QuickSight, Locker Studio o Azure Synapse Dashboards.

2.6. Visualización / Decisión

Tipo	Mejor uso en Big Data	Aplicación
Barras	Comparar magnitudes entre categorías	Volumen de transacciones por país
Columnas	Comparar series en el tiempo (meses, años, horas)	Consumo energético diario en una smart city
Tarta	Mostrar % de un total (pocas categorías, máx. 4–5)	Distribución de cuota de mercado por competidor
Líneas	Mostrar tendencias y evolución en el tiempo	Tráfico web por hora en una campaña de marketing digital

2.6. Visualización / Decisión

Tipo	Mejor uso en Big Data	Aplicación
Dispersión	Visualizar relación entre dos variables	Precio de vivienda vs. distancia al centro en una ciudad
Histogramas	Mostrar distribución de una variable	Distribución de duración de sesiones de usuario en una app
Heatmap	Identificar patrones y correlaciones en grandes matrices	Tráfico de red por hora y día de la semana
Tarjetas KPI	Resumir métricas clave de forma clara e inmediata	Ingresos = 2.3M€, Clientes activos = 1.2M, Retención = 87%

2.6. Visualización / Decisión

Catálogo Tipos de Gráficos



CONTENIDOS

1. Del dato en crudo a la decisión.
2. Ecosistema Big Data y Cadena de valor del dato.
3. **Retos y Consideraciones.**

Universidad Europea

3. Retos y Consideraciones

Escalabilidad

- El sistema debe crecer con los datos sin colapsar.
- *Ejemplo: Twitter procesa millones de tweets por minuto.*

Calidad y Gobierno del dato

- Datos erróneos → decisiones equivocadas.
- Gobierno = quién accede, cómo se gestiona, trazabilidad.

Universidad Europea

3. Retos y Consideraciones

Seguridad

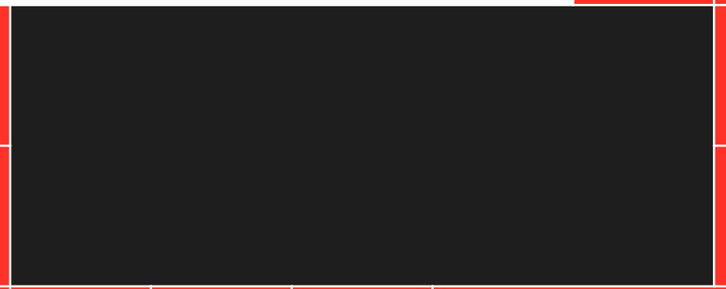
- Riesgos de brechas de datos (ej. Cambridge Analytica).
- Ejemplo: Normativas: GDPR, LOPDGDD.

Costes Asociados

- Almacenamiento.
- Procesamiento.
- Personal cualificado.

Universidad Europea

Disfrutemos de lo aprendido



Ve más allá

© Copyright Universidad Europea. Todos los derechos reservados