Universidad Europea



Componentes tecnológicos

Ecosistema Big Bata

Fundamentos de Big Data

Grado en Física

Universidad Europea

““Si tuvieras que construir una arquitectura Big Data desde cero, ¿por dónde empezarías: por los datos, por las herramientas o por el almacenamiento?”

Universidad Europea

Conclusión

La **tecnología** es un **medio, no un fin**. La **infraestructura** tecnológica debe diseñarse a partir de las **necesidades** del **negocio** y del tipo de **datos**.

CONTENIDOS

1. **Principales componentes tecnológicos.**
2. Tecnologías de Ingesta de datos.
3. Tecnologías de Almacenamiento.
4. Tecnologías de Procesamiento.
5. Tecnologías de Análisis y Visualización.

Universidad Europea

1. Principales Componentes Tecnológicos

- ***Ingesta de datos***: *capturar y transportar información desde múltiples fuentes.*
- ***Almacenamiento***: *guardar los datos de manera escalable y segura.*
- ***Procesamiento***: *transformar, limpiar y preparar los datos para su análisis.*
- ***Análisis y visualización***: *convertir los datos en conocimiento y decisiones.*

Sin estos componentes, los modelos teóricos (lambda, kappa, etc.) no podrían operar en la práctica.

CONTENIDOS

1. Principales componentes tecnológicos.
2. **Tecnologías de Ingesta de datos.**
3. Tecnologías de Almacenamiento.
4. Tecnologías de Procesamiento.
5. Tecnologías de Análisis y Visualización.

Universidad Europea

2. Tecnologías de Ingesta

- La ingesta es el proceso que permite ***recolectar, importar y transportar datos*** desde diversas fuentes hacia los sistemas de almacenamiento o procesamiento.
- Debe garantizar: *Fluidez, Escalabilidad y Fiabilidad.*

***Ejemplo**: en un e-commerce, los clics de los usuarios (clickstream) se recogen con Kafka, se enrutan y enriquecen con NiFi y se almacenan en HDFS mediante Flume.*

2.1. Tipos de Ingesta

Batch ingestion

- Carga datos en intervalos definidos (cada hora, día, etc.).
- *Ejemplo: reportes de ventas diarios.*

Streaming ingestion

- Procesa flujos de datos en tiempo real.
- *Ejemplo: eventos de usuarios, sensores IoT, transacciones bancarias.*

2.2. Herramientas Principales

Herramienta	Función principal	Características clave	Ejemplo de uso
Apache Kafka	Plataforma distribuida de mensajería en tiempo real	Alta velocidad, tolerancia a fallos, persistencia y replicación de mensajes	Captura de eventos en un sitio web, logs de aplicaciones, IoT
Apache NiFi	Orquestación y transformación visual de flujos	Basado en interfaz gráfica, permite enrutar, filtrar y priorizar datos	Integrar datos de marketing, CRM y ventas en un flujo único
Apache Flume	Recolección continua de logs y eventos	Ideal para ingesta masiva de datos no estructurados	Captura de logs de sensores o redes industriales

CONTENIDOS

1. Principales componentes tecnológicos.
2. Tecnologías de Ingesta de datos.
3. **Tecnologías de Almacenamiento.**
4. Tecnologías de Procesamiento.
5. Tecnologías de Análisis y Visualización.

Universidad Europea

3. Tecnologías de Almacenamiento

- El almacenamiento busca mantener grandes volúmenes de datos de forma ***segura, accesible y escalable***, tanto para consulta histórica como para procesamiento intensivo.
- Data Lake: ideal para almacenar datos diversos sin transformación previa.
- DWH: análisis estructurados y reporting empresarial.
- Entornos Híbridos: se usa el concepto de Lakehouse, que combina ambos enfoques.

3.1. Tipos de Almacenamiento

Tipo	Características	Tecnologías representativas
Bases relacionales (SQL)	Datos estructurados, esquema fijo, integridad referencial.	PostgreSQL, MySQL, Oracle.
Bases NoSQL	Datos semiestructurados o no estructurados, flexibles, escalables horizontalmente.	MongoDB (documental), Cassandra (columna), Redis (clave-valor), Neo4j (grafo).
Data Lake	Repositorio de datos crudos en su formato original. *Schema-on-read*. Bajo coste.	Hadoop HDFS, Amazon S3, Azure Data Lake.
Data Warehouse (DWH)	Datos estructurados y optimizados para consultas analíticas. *Schema-on-write*.	Snowflake, Google BigQuery, Amazon Redshift.

3.2. Casos de Uso

- Data Lakes: análisis predictivo, aprendizaje automático, IoT.
- NoSQL: aplicaciones en tiempo real con millones de usuarios (Twitter, WhatsApp).
- DWH: informes financieros o regulatorios.

***Ejemplo**: Los sistemas HDFS y Cassandra son ejemplos paradigmáticos de almacenamiento distribuido y replicado*

CONTENIDOS

1. Principales componentes tecnológicos.
2. Tecnologías de Ingesta de datos.
3. Tecnologías de Almacenamiento.
4. **Tecnologías de Procesamiento.**
5. Tecnologías de Análisis y Visualización.

Universidad Europea

4. Tecnologías de Procesamiento

Transformar, limpiar, agregar y analizar los datos, extrayendo información de manera eficiente y escalable.

- ***Spark*** puede operar en modo híbrido, combinando batch y flujos en tiempo real (streaming).
- ***Flink*** se centra en la baja latencia y la precisión temporal, ideal para casos donde los datos llegan en continuo.
- ***Hadoop*** es la base del ecosistema (HDFS + YARN + MapReduce).

4.1. Herramientas Principales

Herramienta	Enfoque	Características	Casos de uso
Apache Hadoop	Batch (por lotes)	Procesamiento distribuido con MapReduce; tolerancia a fallos y escalabilidad horizontal.	Procesar grandes históricos de datos, informes masivos.
Apache Spark	Batch + Streaming	Procesamiento en memoria (hasta 100x más rápido que MapReduce). Incluye módulos Spark SQL, MLlib, GraphX, Streaming.	Clickstream, predicción de demanda, detección de fraude.
Apache Flink	Streaming	Procesamiento de eventos con latencia mínima; orientado a datos en flujo.	IoT, analítica en tiempo real, detección de anomalías.

***Ejemplo**: Una empresa de transporte procesa sus datos GPS en tiempo real con Flink (para alertas inmediatas) y en batch con Spark (para análisis de rutas y eficiencia).*

CONTENIDOS

1. Principales componentes tecnológicos.
2. Tecnologías de Ingesta de datos.
3. Tecnologías de Almacenamiento.
4. Tecnologías de Procesamiento.
5. **Tecnologías de Análisis y Visualización.**

Universidad Europea

5. Tecnologías de Análisis y Visualización

*Transformar los resultados del procesamiento en **insights comprensibles y accionables** para el negocio.*

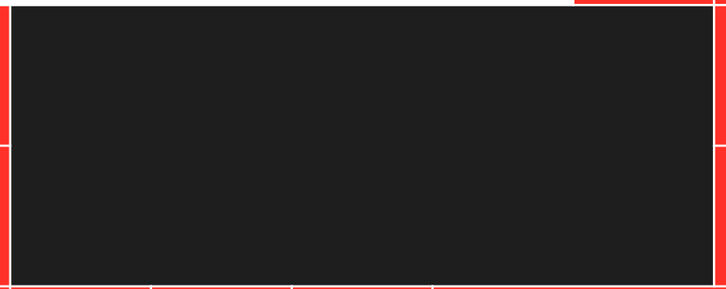
- ***Hive**: análisis estructurado sobre datos almacenados en HDFS.*
- ***Tableau / Power BI**: cuadros de mando ejecutivos o informes de rendimiento.*
- ***Kibana**: monitorización de logs de sistemas (con ELK Stack).*

5.1. Herramientas Principales

Tipo	Herramientas	Funcionalidades clave
Consultas y análisis en Hadoop	Hive, Pig	Consultas SQL sobre grandes volúmenes de datos distribuidos (Hive) y flujos de procesamiento declarativos (Pig).
Business Intelligence (BI)	Tableau, Power BI, Looker	Dashboards, reporting dinámico, KPIs visuales.
Visualización avanzada	D3.js, Plotly, Kibana	Gráficos interactivos, mapas geoespaciales, storytelling visual.

Universidad Europea

Disfrutemos de lo aprendido



Ve más allá

© Copyright Universidad Europea. Todos los derechos reservados